AKADEMIA E FORCAVE
TË ARMATOSURA

# Hyrje në Modele të Mëdha Gjuhësore

## Përshtatja e modelit - Fine tuning

Dr. Fiorela Ciroku

# Fine - tuning

**Fine-tuning është procesi i ritrajnimit të pjesshëm ose të plotë të një modeli të trajnuar paraprakisht**, me qëllim që ai të përshtatet më mirë ndaj:

- një detyre specifike,
- një domeni të caktuar,
- ose një stili/forme të sjelljes.

Ndryshe nga prompting ose RAG, fine-tuning **ndryshon vetë parametrat e modelit**, pra sjellja e re bëhet **e përhershme**.

# Pse fine-tuning?

**Fine-tuning përdoret kur:**

- promptet bëhen shumë komplekse dhe të paqëndrueshme,
- kërkohet sjellje konsistente në shumë kërkesa,
- ose modeli duhet të përvetësojë një stil ose strukturë të re përgjigjeje.

Në domene si **mbrojtja civile**, nuk mjafton që modeli *ndonjëherë* të përgjigjet saktë; kërkohet **sjellje e parashikueshme dhe e standardizuar**.

# Fine tuning VS Prompt VS RAG

- **Prompting** kontrollon *si* i flasim modelit, por nuk ndryshon asgjë brenda tij.
- **RAG** shton informacion të jashtëm, por modeli mbetet i njëjtë; sjellja varet nga dokumentet e rikthyera.
- **Fine-tuning** është i vetmi mekanizëm që **ndryshon vetë modelin**, prandaj ka efekt afatgjatë dhe rrezik më të lartë.

Një sistem i sofistikuar shpesh kombinon të treja, por zgjedh me kujdes cilin mekanizëm për cilin problem.

# Fine tuning VS Prompt VS RAG

| Dimension | Prompting | RAG | Fine-Tuning |
|---|---|---|---|
| Çfarë ndryshon | Input-i (instruksioni) | Konteksti i dhënë modelit | Parametrat e modelit |
| Ndryshim i përhershëm | Jo | Jo | Po |
| Ndikimi në sjellje | Lokal, për një kërkesë | Lokal, i kushtëzuar nga dokumentet | Global dhe afatgjatë |
| Ndikimi në njohuri | Asnjë | Dinamik, nga burime të jashtme | Indirekt, përmes modeleve statistikore |
| Burimi i informacionit | Njohuritë ekzistuese të modelit | Dokumente të rikthyera (external) | Dataset-i i fine-tuning |

# Fine tuning VS Prompt VS RAG

| Dimension | Prompting | RAG | Fine-Tuning |
|---|---|---|---|
| Auditability | E ulët | E lartë | E ulët–mesatare |
| Fleksibiliteti | Shumë i lartë | I lartë | I ulët |
| Kosto operacionale | Shumë e ulët | Mesatare | E lartë |
| Rreziku i halucinacioneve | I lartë | I ulët | Mesatar |
| Kur përdoret | Eksperimentim, kontroll i shpejtë | Njohuri faktike, dokumente zyrtare | Stil, strukturë, sjellje e standardizuar |
| Shembull (Mbrojtje Civile) | Formulim i përgjigjes | Përdorim i protokolleve zyrtare | Standardizim i raporteve operative |

# Çfarë mund të mësojë modeli me Fine-Tuning?

Fine-tuning nuk është vetëm për njohuri faktike. Ai përdoret shpesh për:

- të mësuar format të caktuar output-i,
- të standardizuar terminologjinë,
- të mësuar kur dhe si të refuzohet një kërkesë.

Në mbrojtje civile, kjo mund të nënkuptojë:

- përgjigje gjithmonë në formë hapash,
- përdorim të termave zyrtarë,
- refuzim të pyetjeve jashtë kompetencës.

# Çfarë mund të mësojë modeli me Fine-Tuning?

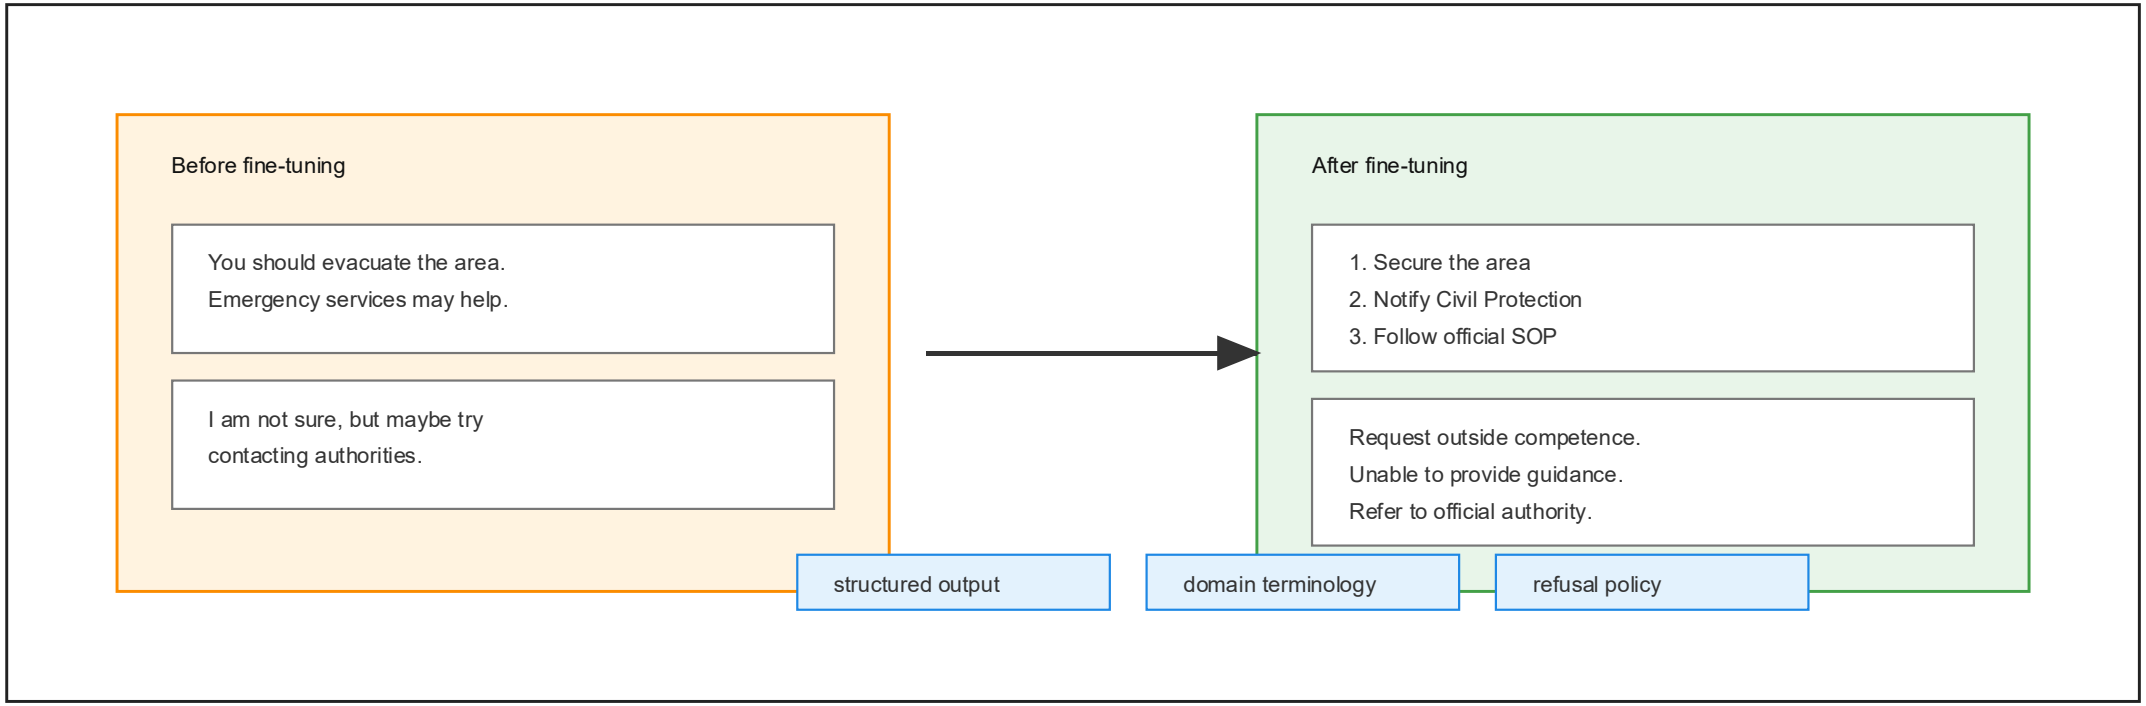

# Çfarë **nuk** është Fine-Tuning?

- Fine tuning nuk është retrieval, nuk është prompt engineering, nuk garanton korrektësi faktike, dhe nuk zëvendëson dokumentet zyrtare.
- Një keqkuptim i zakonshëm është se fine-tuning “i fut” dokumentet brenda modelit.
- Në realitet, modeli nuk “ruan” dokumente, por mëson modele statistikore të sjelljes nga të dhënat.
- Për njohuri që ndryshojnë shpesh (ligje, procedura), RAG është më i përshtatshëm se fine-tuning.

# Llojet kryesore të Fine-Tuning

- **Supervised Fine-Tuning (SFT)** - trajnim i drejtpërdrejtë me çifte input-output.
- **Parameter-Efficient Fine-Tuning (PEFT)** - ndryshim i një pjese të vogël të parametrave.
- **Reinforcement Learning from Feedback (RLHF/RLAIF)** - optimizim i sjelljes bazuar në feedback.
- Këto teknika nuk janë konkurruese; shpesh përdoren së bashku.

# Supervised Fine-Tuning (SFT)

SFT është forma klasike: *modeli sheh një input dhe mëson të prodhojë output-in e dëshiruar*.

Rreziku kryesor është që modeli:

- të mësojë gabime nga dataset-i,
- ose të mbingarkohet me shembuj shumë specifik .

Në domene kritike, datasetet duhet të jenë të kuruara, të rishikuara nga ekspertë, dhe të versionuara.

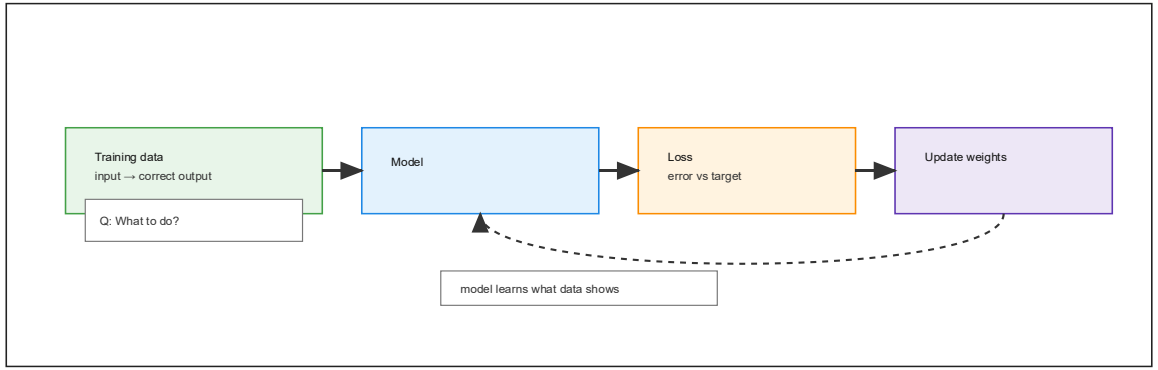

# Parameter-Efficient Fine-Tuning (PEFT)

PEFT u zhvillua sepse modelet moderne janë shumë të mëdha për fine-tuning të plotë.

Teknika si LoRA, adapters, prefix-tuning:

- ngrijnë shumicën e peshave,
- dhe mësojnë vetëm shtresa të vogla shtesë.

Kjo lejon adaptim të shpejtë, shumë versione të specializuara, dhe rollback të lehtë.

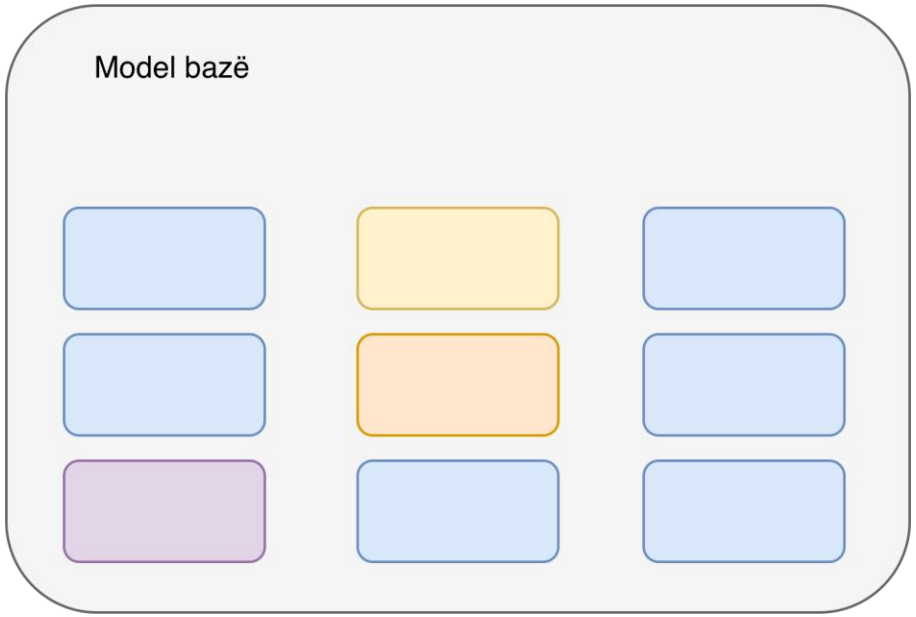

# PEFT: LoRA, Adapters & Prefix-Tuning

**LoRA (Low-Rank Adaptation):**

- Shton **matrica të vogla low-rank** në disa shtresa (zakonisht attention)
- Nuk ndryshon peshat origjinale
- Shumë efikase në memorie

**Adapters:**

- Shtresa të vogla **plug-in** midis shtresave ekzistuese
- Çdo task ka adapter-in e vet
- Modeli bazë ndahet nga logjika e specializuar

# PEFT: LoRA, Adapters & Prefix-Tuning

**Prefix-Tuning:**

- Nuk prek peshat fare
- Mëson vetëm token-e shtesë (prefix) që i shtohen input-it
- Kontrollon sjelljen e modelit përmes kontekstit

| Teknikë | Çfarë mësohet | Çfarë ndryshon |
|---|---|---|
| LoRA | Matrica të vogla | Attention behavior |
| Adapters | Mini-network | Flow i brendshëm |
| Prefix | Token-e virtuale | Konteksti i input-it |

# RLHF / RLAIF

RLHF (Human Feedback) dhe RLAIF (AI Feedback) përdoren për:

- përmirësuar ndjekjen e instruksioneve,
- ulur sjellje të padëshiruara,
- dhe rregulluar tonin e modelit.

Këto teknika janë të fuqishme, por kërkojnë pipeline kompleks, dhe janë më pak të përdorshme në projekte të vogla.

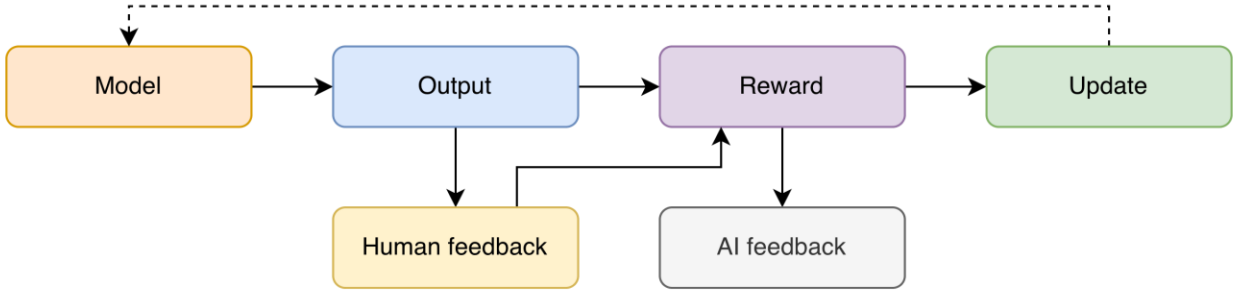

# Fine-Tuning për Domenin

Në mbrojtje civile, fine-tuning përdoret për:

- të standardizuar mënyrën e përshkrimit të incidenteve,
- të mësuar fjalor institucional,
- të përforcuar refuzime ndaj pyetjeve spekulative.

Por dokumentet zyrtare nuk duhet të kodohen drejtpërdrejt në model nëse ndryshojnë shpesh.

# Rreziqet e Fine-Tuning

Fine-tuning i pakujdesshëm mund të:

- prishë aftësitë e përgjithshme të modelit,
- bëjë modelin shumë “të ngushtë”,
- ose të amplifikojë bias-e ekzistuese.

Kjo është arsyeja pse PEFT preferohet, dhe vlerësimi pas fine-tuning është kritik.

# Kur nuk duhet përdorur Fine-Tuning

Fine-tuning është i shtrenjtë dhe i rrezikshëm nëse përdoret gabimisht.

Fine tuning nuk duhet përdorur kur:

- Njohuritë që ndryshojnë shpesh
- Mungojnë të dhëna cilësore
- Kërkohet transparencë burimesh
- Prompt/RAG mjaftojnë

# Kur nuk duhet përdorur Fine-Tuning

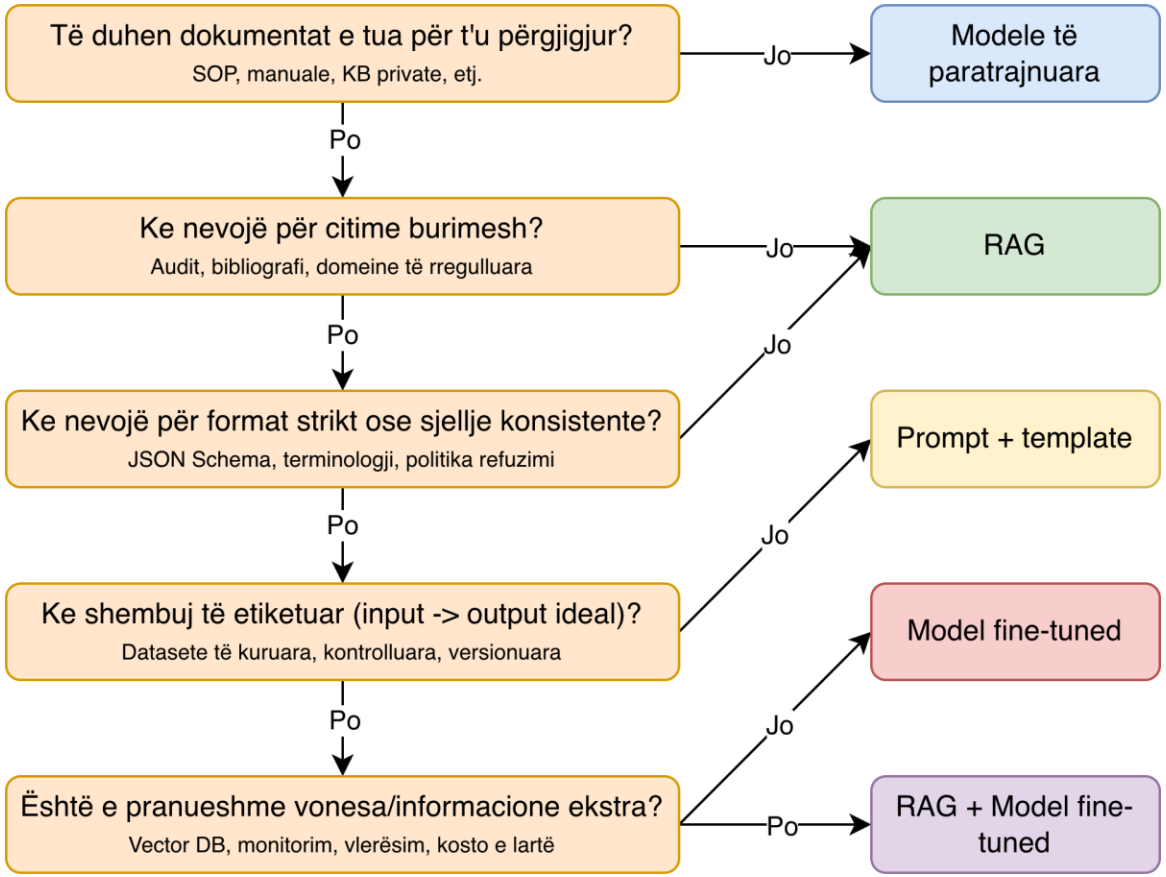

# Vlerësimi pas Fine-Tuning

Pas fine-tuning duhet të verifikohet:

- a është përmirësuar detyra target,
- a janë ruajtur aftësitë e përgjithshme,
- a janë shfaqur sjellje të reja të padëshiruara.

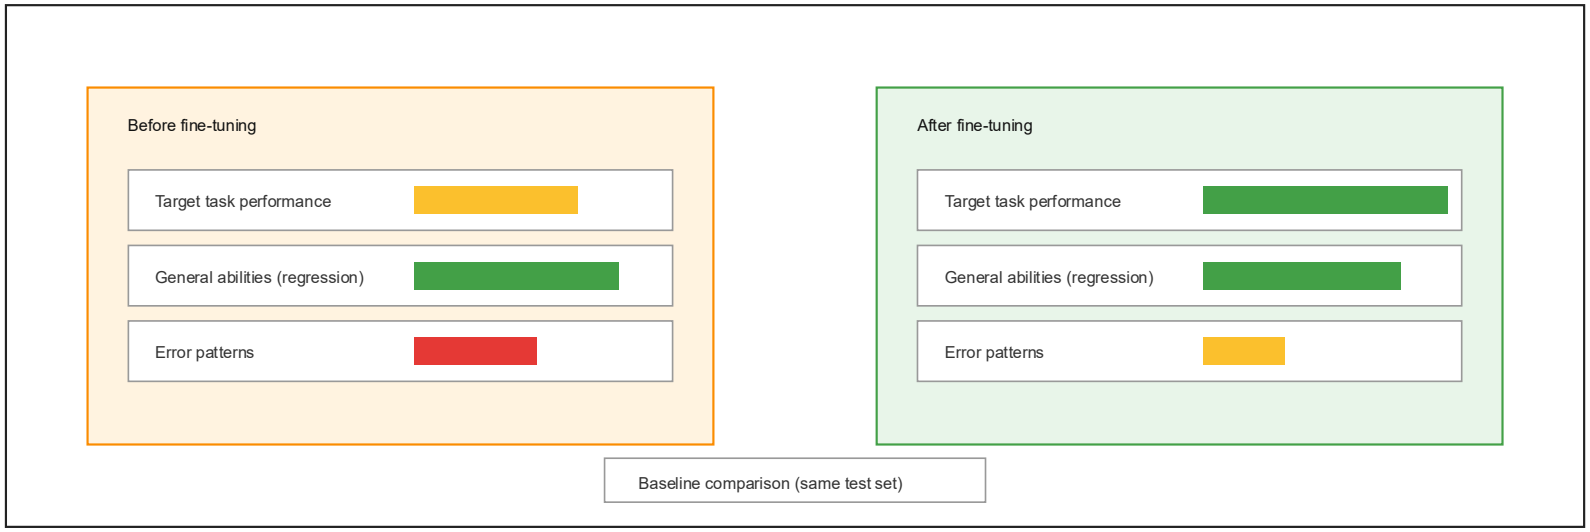

# Vlerësimi pas Fine-Tuning

Bëhet:

- ***Testim në detyrë specifike:*** Modeli testohet në detyrën target për të verifikuar nëse fine-tuning ka sjellë përmirësim real të performancës.
- ***Regresion test për aftësi bazë:*** Kryhen teste regresioni për të siguruar që aftësitë e përgjithshme të modelit nuk janë degraduar pas fine-tuning.
- ***Analizë e gabimeve:*** Analiza e gabimeve ndihmon në identifikimin e sjelljeve të reja të padëshiruara ose modeleve sistematike të dështimit.
- ***Krahasim me baseline:*** Performanca e modelit të fine-tunuar krahasohet me modelin bazë për të vlerësuar nëse ndryshimet janë vërtet të justifikuara.

# Çfarë do të trajtojmë në vazhdimësi?

- ✓ Hyrje
- ✓ Tokenizimi & Embeddings
- ✓ Arkitektura Transformer
- ✓ Bazat e të dhënave vektoriale (Vector Databases)
- ✓ RAG (Gjenerim i përforcuar nga kërkimi)
- ✓ Promptimi
- ✓ Agjentët (Agents)
- ✓ Përshtatja e modelit (Fine-Tuning)

9. Vlerësimi (Evaluation)
10. Siguria & Përafrimi (Safety & Alignment)
11. Vendosja e modelit (Deployment)
12. Integrimi i Projektit Final

# Bibliografia


1. H. Touvron *et al.*, “LLaMA: Open and Efficient Foundation Language Models,” *arXiv*, 2023.
2. E. Hu *et al.*, “LoRA: Low-Rank Adaptation of Large Language Models,” *Proc. ICLR*, 2022.
3. J. Devlin *et al.*, “BERT: Pre-training of Deep Bidirectional Transformers,” *Proc. NAACL*, 2019.
4. L. Ouyang *et al.*, “Training Language Models to Follow Instructions with Human Feedback,” *arXiv*, 2022.
5. S. Min *et al.*, “Rethinking the Role of Demonstrations,” *Proc. EMNLP*, 2022.
6. S. Dettmers *et al.*, “QLoRA: Efficient Finetuning of Quantized LLMs,” *Proc. NeurIPS*, 2023.