AKADEMIA E FORCAVE
TË ARMATOSURA

# Hyrje në Modele të Mëdha Gjuhësore

## Vlerësimi i modeleve dhe sistemeve me MMGj

Dr. Fiorela Ciroku

# Vlerësimi i modeleve dhe sistemeve me MMGj

- Vlerësim i modeleve ≠ vlerësim i sistemeve (**arkitekturave të plota** si RAG, agjentë, fine-tuning)

- Zgjedhja e metodës së vlerësimit varet nga si faktorë si:

  - **Detyra:** Çfarë po kërkohet që sistemi të bëjë?
  - **Konteksti:** Në çfarë mjedisi do të përdoret sistemi?
  - **Rreziku:** Çfarë ndodh nëse sistemi gabon?

- Një sistem MMGj që sugjeron veprime në rast fatkeqësie natyrore, nuk mund të vlerësohet vetëm me BLEU ose ngjashmëri semantike. Duhet gjithashtu verifikim nga ekspertë, testim në skenarë ekstremë, dhe kontroll të refuzimeve të duhura.

# Detyra, konteksti dhe rreziku

- Detyra:
  - Të mbyllura (p.sh. klasifikim, ekstraktim): metrika automatike janë shpesh të mjaftueshme.
  - Të hapura (p.sh. përgjigje narrative, përmbledhje, asistencë): kërkohet vlerësim semantik dhe njerëzor.

- Konteksti:
  - Kontekst operacional / publik / institucional: kërkohet vlerësim më rigoroz, gjurmueshmëri dhe siguri.
  - Kontekst eksperimental / akademik: tolerancë më e lartë për gabime.

- Rreziku:
  - Rrezik i ulët (p.sh. rekomandim filmi): vlerësim i lehtë, fokus në përvojë përdoruesi.
  - Rrezik i lartë (p.sh. mbrojtje civile, shëndetësi, ligj): kërkohet vlerësim njerëzor, teste sigurie, stress testing, dokumentim formal i kufijve.

# Pse vlerësimi është problematik për MMGj?

**Ndryshe nga NLP klasik, ku detyrat janë të mbyllura, MMGj-të** gjenerojnë tekst të hapur, kanë variabilitet të lartë, dhe shpesh nuk ekziston një përgjigje e vetme e saktë.

Kjo e bën vlerësimin:

- më pak matematik,
- më shumë metodologjik,
- dhe shumë të varur nga konteksti i përdorimit.

# Çfarë po vlerësojmë saktësisht?

**Vlerësimi duhet të nisë nga pyetja: “Cili aspekt i sistemit është kritik për këtë aplikim?”**

- Saktësi faktike
- Rëndësinë ndaj pyetjes
- Koherencë dhe qartësi
- Siguri dhe përputhje me politika
- Efikasitet (latencë, kosto)

Në një sistem për mbrojtje civile, rëndësi më të madhe kanë korrektësia faktike, përputhja me protokollet dhe refuzimi korrekt i pyetjeve të rrezikshme.

# Çfarë po vlerësojmë saktësisht?

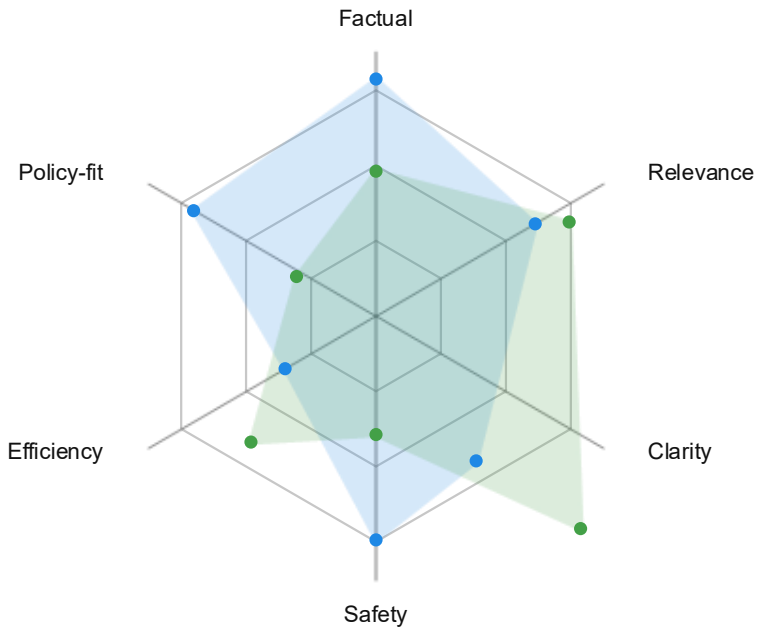


civil protection profile

creative app profile

weights depend on application

# Vlerësimi i modelit VS  vlerësimi i sistemit

- **Një model mund të jetë i mirë, por mund të përdoret në një sistem të keq, dhe anasjelltas.**

- **Shembull,** modeli ka performancë të lartë, por RAG rikthen dokumente të gabuara, ose agjenti përdor mjetin e gabuar.

- Prandaj, **vlerësimi duhet të bëhet në nivel sistemi**, jo vetëm modeli. Vlerësimi duhet të pasqyrojë përdorimin real

# Vlerësimi i modelit VS vlerësimi i sistemit

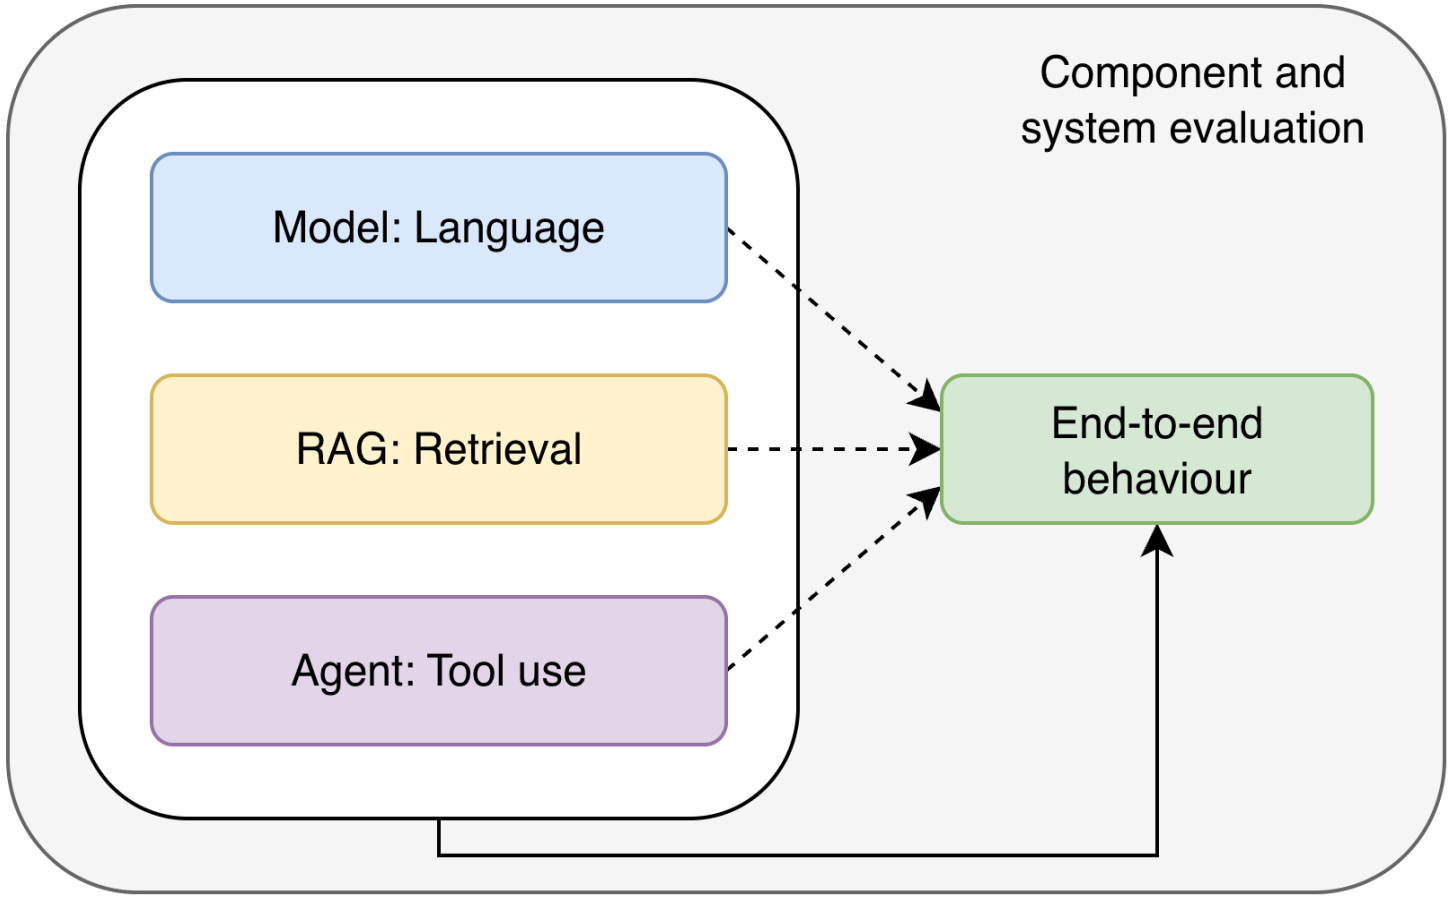

# Metrikat automatike klasike

***BLEU (Bilingual Evaluation Understudy)*:** Mat sa shumë n-gramë (sekuenca fjalësh) në tekstin e gjeneruar përputhen me tekstin reference; përdoret kryesisht në përkthim automatik dhe favorizon saktësinë (precision).

**Tekst reference:** “Civil Protection issued a flood warning for northern regions.”

**Tekst i gjeneruar:** “Civil Protection issued a flood warning for the northern area.”

**Pse BLEU është i lartë:** Shumica e fjalëve dhe n-gramëve përputhen saktësisht (issued, flood warning, northern), ndaj BLEU vlerëson mirë këtë output, edhe pse ka një ndryshim të vogël (“regions” vs “area”).

# Metrikat automatike klasike

***ROUGE (Recall-Oriented Understudy for Gisting Evaluation)*:** Mat sa shumë nga përmbajtja e tekstit reference është mbuluar nga teksti i gjeneruar; përdoret shpesh për përmbledhje automatike dhe fokusohet te recall.

**Tekst reference:** “During the storm, Civil Protection coordinated evacuations, road closures, and emergency shelters.”

**Tekst i gjeneruar:** “Civil Protection coordinated evacuations and emergency shelters during the storm.”

**Pse ROUGE është i lartë:** Teksti i gjeneruar mbulon pjesën më të madhe të informacionit kyç nga referenca, edhe pse mungon “road closures”; kjo është tipike për ROUGE në përmbledhje.

# Metrikat automatike klasike

***METEOR (Metric for Evaluation of Translation with Explicit ORdering)*:** Vlerëson përputhjen duke marrë parasysh sinonime, forma gramatikore dhe renditjen e fjalëve, duke ofruar një korrelacion më të mirë me vlerësimin njerëzor.

**Tekst reference:** “Civil Protection warned citizens to remain indoors due to extreme heat.”

**Tekst i gjeneruar:** “Civil Protection advised people to stay inside because of severe heat.”

**Pse METEOR është i lartë:** METEOR njeh përputhje semantike si: *warned* ↔ *advised; citizens* ↔ *people; extreme* ↔ *severe; remain indoors* ↔ *stay inside.*

# Metrikat automatike klasike

| Metric | Range | Low score | Medium score | High score | Interpretim tipik |
|---|---|---|---|---|---|
| BLEU | 0–1 (0–100) | < 0.20 | 0.20–0.30 | > 0.30 | Përputhje leksikore (precision), kryesisht për përkthim. |
| ROUGE-1 / ROUGE-L | 0–1 | < 0.20 | 0.20–0.40 | > 0.40 | Mbulim i përmbajtjes (recall), përdoret për përmbledhje. |
| METEOR | 0–1 | < 0.20 | 0.25–0.35 | > 0.40 | Përputhje semantike, korrelon me vlerësim njerëzor. |

# Metrikat automatike klasike

- Në sisteme MMGj, këto metrika janë indikative, jo vendimtare, dhe nuk duhet përdorur si kriter i vetëm.
- BLEU, ROUGE dhe METEOR nuk kanë vlera absolute ‘pass/fail’; ato përdoren për krahasim relativ me një baseline ose modele alternative.

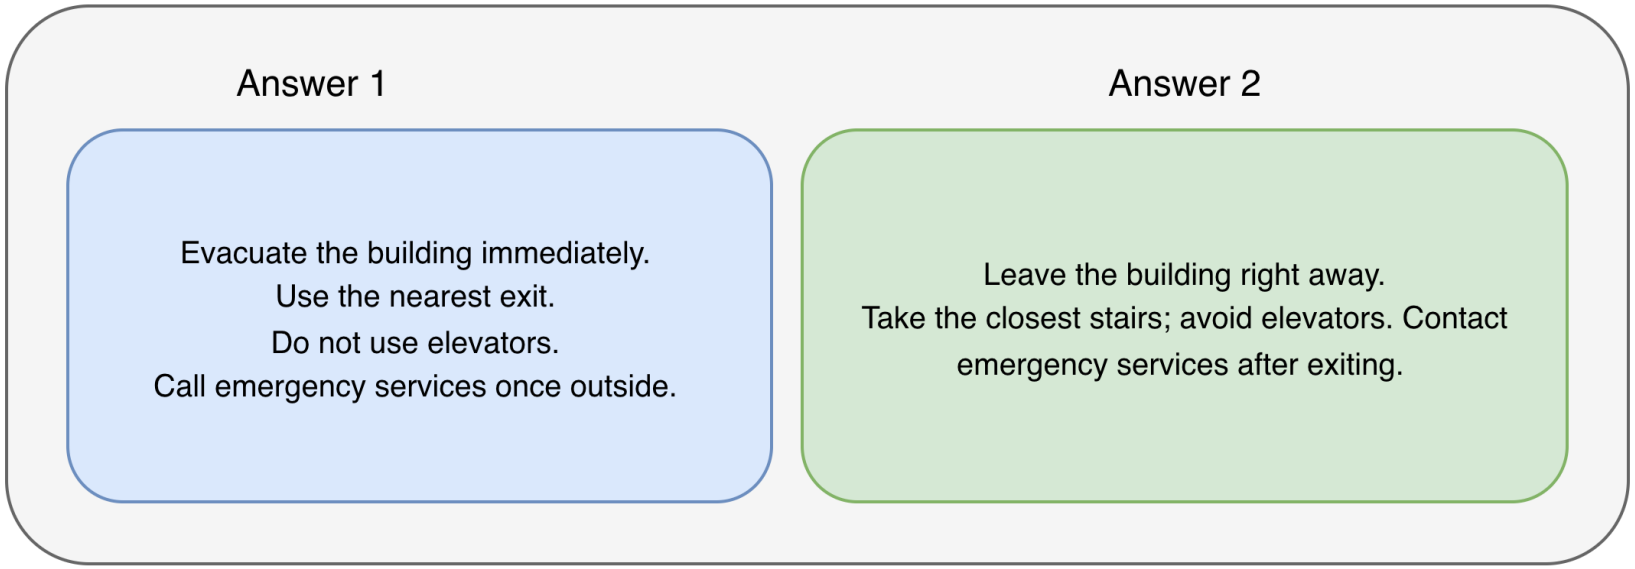

# Vlerësimi Semantik (Embedding-based)

- Vlerësimi semantik përdor embedding-e (vektorë numerikë) për të matur sa afër në kuptim është përgjigja e modelit me tekstin referencë, edhe kur fjalët nuk përputhen saktësisht.
- Nuk varet nga përputhja fjalë-për-fjalë; është tolerante ndaj parafrazimit; kap sinonime dhe struktura të ndryshme gjuhësore.

**Limite kryesore:**

- Rezultati varet nga modeli i embedding-ut.
- Ngjashmëria semantike nuk garanton korrektësi faktike.
- Dy tekste mund të jenë “afër” në kuptim, por njëri të jetë i gabuar.

# Vlerësimi për RAG

Për RAG, duhet të vlerësohen dy gjëra të ndara:

- **Retrieval** – a rikthehen dokumentet e duhura?
- **Generation** – a përdoren saktë këto dokumente?

Metrika tipike:

- **Recall@k** për retrieval,
- **Groundedness**: sa përqind e përgjigjes mbështetet në burime,
- **Faithfulness**: mungesa e hallucinimeve.

# Vlerësimi i agjentëve

**Agjentët nuk vlerësohen me metrics e lartpermendur. Ata vlerësohen si sisteme vendimmarrëse**:

- A e përfundojnë detyrën?
- Sa hapa përdorin?
- zgjedhin mjetin e duhur?
- A ndalen në kohë?

Kjo kërkon **skenarë testimi** dhe **simulime që testojnë:**

- Task success rate
- Numri i hapave
- Përdorimi korrekt i mjeteve
- Stabiliteti i sjelljes

# Vlerësimi i Fine-Tuning

**Pas fine-tuning duhet të pyesim:**

- A u përmirësua detyra për të cilën u trajnua modeli?
- A humbi aftësi të përgjithshme?
- A shfaq sjellje të reja të padëshiruara?

Vlerësimi bëhet përmes testeve si:

- Përmirësim në detyrën target
- Regresion në aftësi bazë
- Krahasim me baseline
- Teste jashtë dataset-it të trajnimit

Pa këto teste, fine-tuning është metodologjikisht i paplotë.

# Vlerësimi Njerëzor

Në shumë raste, ***vetëm ekspertët njerëzorë mund të vlerësojnë korrektësinë procedurale, identifikojnë rreziqe, dhe gjykojnë përdorshmërinë reale.***

Për të qenë të saktë:
- përdoren rubrika të qarta,
- matet marrëveshja mes vlerësuesve,
- dhe dokumentohet procesi.

Vlerësimi bëhet me ekspertë të domeinit; është nje proces I shtrenjtë në kohë dhe kosto.

# LLM-as-a-Judge

- Përdorimi i një MMGj-je për të vlerësuar një tjetër është praktikë në rritje.
- Është i dobishëm për krahasime relative dhe filtrime fillestare.
- Por, nuk është objektiv absolut, dhe nuk duhet përdorur si mjet i vetëm vlerësimi.

Në thelb:

- Automatizon vlerësimin
- Konsistent dhe i shkallëzueshëm
- Mund të trashëgojë bias
- Nuk zëvendëson ekspertët

# Vlerësimi i Sigurisë dhe Përafrimit

Vlerësimi i sigurisë teston:

- çfarë ndodh kur sistemi provokohet,
- nëse refuzimet janë të qëndrueshme,
- nëse sistemi devijon nga politika.

Ky hap është kritik për sisteme publike dhe institucionale.

# Benchmark-et dhe kufinjtë e tyre

- Benchmark-et janë të dobishme për krahasim të përgjithshëm, por nuk pasqyrojnë domene specifike, dhe nuk matin gjithmonë rrezik ose përdorshmëri. Në aplikime reale, nevojiten benchmarks të personalizuara.

- Shembuj benchmark-e :
  - **GLUE (General Language Understanding Evaluation)** është një benchmark që përmbledh disa detyra standarde NLP (klasifikim, inferencë, similarity) për të matur aftësitë e përgjithshme të modeleve gjuhësore.
  - **SuperGLUE** është version më i vështirë i GLUE, i krijuar sepse modelet moderne arritën shpejt rezultate shumë të larta në GLUE dhe nuk dalloheshin më mirë mes tyre.
  - **HELM (Holistic Evaluation of Language Models)** është një benchmark më i gjerë që vlerëson jo vetëm performancën, por edhe **robustness, fairness, bias, dhe rrezikun**, duke reflektuar më mirë përdorimin real.

# Krijimi i një strategjie vlerësimi

- **Përcakto qëllimin dhe rrezikun:** Identifiko qartë përdorimin real të sistemit, detyrën target dhe nivelin e rrezikut (p.sh. informues vs. kritik), sepse kjo drejton gjithë vlerësimin.

- **Zgjidh metrikat e duhura:** Zgjidh metrika që matin atë që ka rëndësi për përdorimin konkret, jo vetëm atë që është standard në literaturë (p.sh. accuracy ≠ përdorshmëri).

- **Kombino vlerësim automatik dhe njerëzor:** Përdor metrika automatike për shkallëzim dhe krahasim, dhe vlerësim njerëzor për cilësi, siguri, dhe kuptim semantik.

- **Analizo dhe dokumento kufijtë:** Dokumento qartë çfarë matet dhe çfarë nuk matet, duke përfshirë raste dështimi, bias të mundshëm dhe skenarë jashtë scope-it.

# Çfarë do të trajtojmë në vazhdimësi?

- ✓ Hyrje
- ✓ Tokenizimi & Embeddings
- ✓ Arkitektura Transformer
- ✓ Bazat e të dhënave vektoriale (Vector Databases)
- ✓ RAG (Gjenerim i përforcuar nga kërkimi)
- ✓ Promptimi
- ✓ Agjentët (Agents)
- ✓ Përshtatja e modelit (Fine-Tuning)
- ✓ Vlerësimi (Evaluation)

10. Siguria & Përafrimi (Safety & Alignment)
11. Vendosja e modelit (Deployment)
12. Integrimi i Projektit Final

# Bibliografia


1. P. Liu *et al.*, “Evaluating Large Language Models: A Survey,” *arXiv*, 2023.
2. S. Liang *et al.*, “Holistic Evaluation of Language Models (HELM),” *Stanford*, 2022.
3. K. Clark *et al.*, “What Does BERT Look At?,” *ACL*, 2019.
4. J. Gehrmann *et al.*, “The GEM Benchmark,” *ACL*, 2021.
5. Y. Gao *et al.*, “RARR: Robust Attribution for RAG,” *EMNLP*, 2023.
6. A. Wang *et al.*, “GLUE: A Multi-Task Benchmark,” *ICLR*, 2019.
7. S. Min *et al.*, “Faithfulness in Text Generation,” *ACL*, 2023.